

OC14 — Rapport technique (livrable 5)

Rapport ≤ 20 pages : POC d'**agent** de triage médical CHSA — données/RGPD, entraînement (SFT+LoRA $\rightarrow$ DPO), l'agent (chaîne LangGraph), évaluation, serving/CI, limites, roadmap. Décision-driven. Le **runbook de démo** (lancement, cas, go/no-go) suit le rapport.

Contents

▼ — Rapport technique — POC d'agent de triage médical (CHSA)

0. Résumé exécutif
1. Contexte & cadrage
- 1.5 Architecture & pipelines (vue d'ensemble)
2. Données & RGPD (méthodologie décision-driven)
3. Entraînement (méthodologie décision-driven)
4. L'agent de triage (architecture)
5. Évaluation & métriques
6. Serving, CI/CD & déploiement
7. Limites (assumées)
8. Roadmap de passage à l'échelle au CHSA
9. Conclusion

► — OC14 — Runbook de démonstration (POC agent de triage CHSA)

[↗ Contents](#)

Rapport technique — POC d'agent de triage médical (CHSA)

Livrable 5 — OpenClassrooms « Finetunez votre propre LLM ». Auteur : Ghislain Delabie · IA Engineer junior · mission Centre Hospitalier Saint-Aurélien (CHSA). Dépôt : github.com/ghislaindelabie/oc14-medical-triage-llm (public). Tous les chiffres cités sont mesurés (sources : `DEVELOPMENT_JOURNAL.md`, `data/cards/DATA_CARD.md`, les logs de runs Kaggle, les fichiers `data/processed/*_stats.json`). Rien n'est estimé sauf mention explicite. Ce document tient en ≤ 20 pages.

Version 2 (2026-07-03). Ajouts depuis la V1 : DPO **corrigé** (`rpo_alpha` $\rightarrow$ +0,018 sans effondrement), recherche d'hyperparamètres (sweep W&B), garde-fou d'entrée hors-distribution, et cadrage honnête de v10.

0. Résumé exécutif [↔ TOC](#)

Le CHSA fait face à une surcharge chronique de son service d'urgences : effectifs de triage tendus, temps d'attente longs, et risque que des cas critiques ne soient pas identifiés assez vite. La Direction Innovation Médicale (Dr. Marie Dubois) m'a confié la réalisation, en quatre semaines, d'un **POC d'agent IA de triage médical** : un assistant qui collecte les symptômes du patient, évalue un **niveau de priorité** (*urgence maximale / modérée / différée*), explique son évaluation, s'intègre au système d'information hospitalier (SIH) et garantit la **traçabilité** de chaque interaction.

Ce que je livre (les cinq livrables du brief) :

1. un **jeu de données médical bilingue** anonymisé et versionné, prêt pour le SFT (~5 600 paires) et le DPO ;
2. un **modèle spécialisé** — Qwen3-1.7B-Base affiné par SFT+LoRA, puis évalué face à une tentative de DPO ;
3. un **endpoint de démonstration** : agent complet exposé par API FastAPI, avec un plan de serving cloud vLLM/RunPod ;
4. un **pipeline CI/CD** GitHub Actions (lint + tests à chaque push, job de déploiement) ;

5. ce rapport technique.

Résultat clé. Sur un jeu de test *gold* stratifié (n=300, décodage déterministe, sans fuite), le fine-tuning fait passer le modèle d'**inutilisable à compétent** : **macro-F1 0,19 (Base non entraîné) → 0,82 (SFT servi)**. Le rappel sur la classe critique *urgence maximale* atteint **0,90 [IC 95 % : 0,83-0,95]**, et le modèle produit toujours le format attendu et l'avertissement de sécurité (taux 1,00 contre 0,68 / 0,00 pour le Base).

Positionnement (essentiel). Ce POC démontre une **méthode** et un **signal de progrès, pas** un trieur autonome déployable. Un rappel de 0,90 sur les urgences vitales (plancher d'intervalle de confiance à 0,83) signifie qu'au moins 1 urgence sur 10 pourrait être manquée dans le pire cas — ce qui est **inacceptable pour un triage autonome**. Je positionne donc l'agent comme un outil d'**aide à la décision sous supervision humaine** (« human-in-the-loop ») : il assiste le personnel soignant, la décision finale reste humaine, il ne pose pas de diagnostic et ne prescrit pas.

1. Contexte & cadrage [↩ TOC](#)

1.1 La mission

Le brief demande un **agent** qui accompagne le patient en (1) collectant ses symptômes via un questionnaire intelligent adaptatif, (2) évaluant le niveau de priorité selon les protocoles médicaux, (3) fournissant des explications claires, (4) s'intégrant au SIH existant, et (5) garantissant la traçabilité pour les audits médicaux. La stratégie du CHSA est en trois phases : validation conceptuelle sur Qwen3-1.7B-Base (phase 1), optimisation ciblée par SFT+LoRA puis DPO (phase 2), projection industrielle vers des modèles 32B+ en cas de succès (phase 3).

1.2 La décision de périmètre : un agent complet, pas seulement un LLM affiné

Le brief demande un **agent** de triage (questionnaire adaptatif, intégration SIH, traçabilité), pas seulement un LLM affiné. J'ai donc traité le fine-tuning du LLM comme le **cœur clinique**, puis — en **dernière étape** — construit autour de lui la **chaîne fonctionnelle complète** du parcours patient : collecte → anonymisation → prétraitement/validation → triage (le LLM) → explication → persistance → intégration SIH. Chaque composant nommé dans le mail du Dr. Dubois est présent et démontrable en direct (détails d'implémentation en §4).

1.3 Carte de conformité (livrable → où c'est démontré)

Livrable / exigence du brief	Où c'est démontré dans ce projet	Statut
L1 — Dataset bilingue anonymisé, versionné, SFT + DPO	data/kaggle_upload/*.jsonl ; DATA_CARD.md ; passe Presidio (audit) ; §2	✓
L1 — Schéma des métadonnées (symptômes / antécédents / constantes / source / confiance)	METADATA_SCHEMA.md ; §2.4	✓
L1 — Justification RGPD	DATA_CARD.md (Recital 26) ; passe Presidio ; §2.5	✓
L1 — Séparation train / éval (auditabilité, pas de fuite)	éval-gold disjointe, audit adverse ; §2, §5	✓
L2 — Modèle Qwen3-1.7B affiné SFT+LoRA puis aligné DPO, poids + métriques	notebooks Kaggle ; adapter LoRA ; SFT v9 servi ; DPO corrigé (rpo_alpha) ; §3, §5	✓ (DPO : effondrement diagnostiqué → corrigé, +0,018 sans effondrement ; v9 servi en V1)
L2 — Traçabilité entraînement (logs, seed, checkpoints)	seed 3407, adapter_config.json , tracking W&B ; §3, §6	✓
L3 — Endpoint cloud vLLM, API de démo, inférence rapide	wrapper FastAPI /triage conteneurisé ; agent FastAPI ; endpoint vLLM déployé sur RunPod (serverless, v9) ; §4, §6	✓ déployé (~2 s à chaud)
L4 — CI/CD GitHub Actions (tests + déploiement)	.github/workflows/ci.yml (ruff + pytest verts + job deploy) ; §6	✓
L5 — Rapport ≤ 20 p (méthodo données + entraînement · métriques · analyse · roadmap)	ce document	✓
Agent — questionnaire adaptatif	agent/questionnaire.py ; §4	✓
Agent — évaluation de priorité selon protocoles	rubrique ESI/MTS ; LLM affiné ; §2.2, §4	✓
Agent — explications claires	nœud explication ; §4	✓
Agent — intégration SIH	mock FHIR R4 ; §4	✓ (simulé)

Livrable / exigence du brief	Où c'est démontré dans ce projet	Statut
Agent — traçabilité pour audits	dossier SQLite, req-id , input_sha256 ; §4	✓

Le reste du rapport détaille chaque ligne, avec l'accent (selon la demande) sur les décisions **Données/RGPD** (§2) et **Entraînement/DPO** (§3), présentées en **Problème** → **Options** → **Décision** → **Critère** → **Preuve**.

1.5 Architecture & pipelines (vue d'ensemble) ↩ TOC

Vue clinique — le parcours de dépistage du patient (ce que voit le personnel soignant ; l'agent *assiste*, le soignant *décide*).



Pipeline d'entraînement — des sources au modèle servi.



Pipeline agentique — le parcours patient au *runtime* (le nœud d'anonymisation est la **frontière RGPD** : au-delà, le **texte brut est effacé** — seul son hash subsiste pour la traçabilité — et seul le **texte anonymisé** circule : contenu clinique lisible, PII masquée).



2. Données & RGPD (méthodologie décision-driven) ↩ TOC

2.1 Sources & licences

Toutes les sources sont **publiques** ; **aucune** n'est un dossier patient réel. La sélection a été guidée par un critère de sûreté juridique (licence redistribuable) et de pertinence à la tâche.

Source	Langue	Licence	Rôle	Statut
ANR-MALADES/ MediQAI	FR	CC-BY-4.0	QA médicale FR + (cas cliniques →) triage	active
keivalya/ MedQuAD	EN	CC-BY-4.0 (Ben Abacha 2019)	QA médicale EN	active
TsinghuaC3I/ UltraMedical-Preference	EN	MIT	paires DPO	<i>collecté pour un essai DPO initial, non retenu (hors-tâche)</i>
qanastek/ FrenchMedMCQA	FR	Apache-2.0	QA MCQ pharmacie FR	désactivée (loader incompatible datasets≥3)
MIETIC / MIMIC (triage)	EN	PhysioNet <i>credentialed</i>	triage EN réel	exclue

Problème (l'exclusion MIETIC/MIMIC). Le seul corpus de triage « réel » facilement accessible (MIETIC) dérive de MIMIC, sous licence PhysioNet **accréditée à non-redistribution**.

Options. (a) l'utiliser et redistribuer discrètement le dérivé ; (b) l'exclure et fabriquer un signal de triage à partir de sources redistribuables.

Décision. Exclure MIETIC/MIMIC.

Critère. Protéger l'histoire « aucune donnée patient réelle / conforme RGPD » et respecter la licence — un POC hospitalier ne peut pas s'affranchir d'une **DUA** (*Data Use Agreement*, accord d'utilisation des données ; celle de PhysioNet interdit la redistribution).

Preuve. Exclusion documentée (`DATA_CARD.md` , recherche 00 §0b). Le signal de triage vient à la place de **deux sources à provenance propre** : principalement les **cas cliniques réels de MediQAI** (questions d'examen ECN) **étiquetés par le consensus de 3 LLM** (§2.2, standard « argent »), complétés par un petit jeu de **vignettes fictives rédigées à la main** (bilingue — signal sécurité + triage EN).

2.2 Étiqueter le triage sans clinicien : le consensus de 3 LLM

Problème. MediQAI est du QA d'examen (QCM), **pas** du triage ; il n'existe **aucun gold** de triage français validé, et **aucun clinicien** n'était disponible pour annoter. La première version utilisait une heuristique de mots-clés (signaux d'alerte) — trop grossière, non défendable.

Options. (a) heuristique de mots-clés ; (b) générer des cas synthétiques ; (c) annoter des cas **réels** par un ou plusieurs LLM de pointe guidés par une rubrique citée.

Décision. Option (c) : labelliser les **3 075 vignettes cliniques réelles** de MediQAI par un **consensus de 3 LLM** — OpenAI `gpt-5.4` , Mistral `medium-3.5` , Anthropic `claude-sonnet-4-6` — chacun renvoyant, dans un même appel, un **niveau 3-classes + son équivalent ESI 1-5**, contre une rubrique citée (`TRIAGE_CRITERIA.md`). Je conserve les cas **unanimes et ESI-cohérents** comme *gold* (évaluation), et les cas majoritaires pour l'entraînement.

Critère. Fiabilité maximale sans clinicien : un consensus multi-modèles réduit le biais d'un modèle unique, la rubrique ancre les décisions dans les protocoles (ESI, MTS, échelles FR : FRENCH/CIMU), et l'accord inter-annotateurs se **mesure** (Fleiss κ).

Preuve. Sur les 3 075 cas × 3 modèles : **Fleiss $\kappa \approx 0,67$** (accord « substantiel »), **1 603 cas unanimes + ESI-cohérents** retenus comme *gold*. Coût total maîtrisé (36,67 \$ grâce au *prompt caching* : 73 % des *tokens* servis depuis le cache côté OpenAI, 91 % côté Anthropic). C'est **explicitement un standard « argent »** (LLM-annotateur), pas une validation clinique — assumé (voir §7).

La rubrique collapse les 5 niveaux ESI vers 3 niveaux, une fois, de façon transparente et monotone :

Niveau	ESI	Sens	Exemple de signal d'alerte (⇒ ce niveau)
urgence maximale	1-2	menace vitale/fonctionnelle, ne peut pas attendre	douleur thoracique (SCA), détresse respiratoire, AVC (FAST), sepsis/choc, GCS<13...
urgence modérée	3	symptomatique, à évaluer promptement, stable	infection fébrile focale, douleur modérée, fracture suspectée mais appui possible...
urgence différée	4-5	non urgent / ambulatoire / administratif	rhume léger, renouvellement d'ordonnance, certificat, conseil de prévention...

Règle décisive : **en cas de doute, sur-trier** (choisir le niveau le plus urgent) — le sous-triage est l'erreur dangereuse.

2.3 Composition du jeu final (livré, vérifiable)

Le jeu final n'est **pas** un corpus purement synthétique : c'est un **mélange de trois briques**, dont seule l'*étiquette de triage* est générée.

- Q&A médical (3 557 lignes) — paires réelles des sources, telles quelles.** `mediqal_mcqu` (2 166), `mediqal_oeq` (396) et `medquad` (995) : leurs paires question→réponse **existantes**, reprises pour donner au modèle les **connaissances médicales** et le **bilinguisme**. Ces sources **ne portent aucune étiquette de triage** (ton intuition est juste) — on ne s'en sert donc que pour le Q&A.
- Triage (1 953 lignes `llm_triage`) — cas réels + étiquette générée.** Faute d'étiquettes de triage dans les sources, j'ai pris les **vrais cas cliniques de MediQAI** (champ `clinical_case`, vignettes d'examen) et **génééré le niveau + la justification par le consensus de 3 LLM** (§2.2). → les **cas sont réels**, seules les **étiquettes** sont générées (standard « argent »). C'est ça, la partie « synthétique » — au niveau des labels, pas des cas.
- Vignettes rédigées à la main (88 lignes = ~11 × 8) — fictives, à provenance propre.** Un petit jeu que j'ai écrit à la main (signal sécurité + triage EN).

L'**éval gold (300)** provient aussi du consensus 3-LLM (les cas les plus fiables), **mise de côté** et disjointe du train. Le DPO est un jeu de préférences de triage **équilibré par direction d'erreur**.

Jeu	Train / Val	Détail
SFT	5 598 / 562	Langue : fr 4 571 / en 1 027 (~82 % FR). Type : triage 2 041 / QA 3 557.
↳ sources SFT		<code>mediqal_mcqu</code> 2 166 · <code>llm_triage</code> 1 953 · <code>medquad</code> 995 · <code>mediqal_oeq</code> 396 · <code>vignette</code> 88
↳ urgence (rows triage)		maximale 1 098 · modérée 689 · différée 254
DPO	211 / 24	équilibré par direction : <code>dpo_under</code> 103 · <code>dpo_mod</code> 50 · <code>dpo_over</code> 48 · <code>safety</code> 10
Éval gold	300	stratifié 100 / 100 / 100 (maximale / modérée / différée)

Composition du jeu SFT (train, 5 598 lignes) — en un coup d'œil.

QA médical 3 557	Triage (cas réels + labels 3-LLM) 1 953
------------------	---

Urgence (lignes triage, 2 041)

maximale 1 098	modérée 689	différée 254
----------------	-------------	--------------

Seule l'étiquette de triage est générée (consensus 3-LLM) ; les cas et les paires QA sont réels. Le sur-triage du corpus d'examen (~47 % maximale) motive le rééquilibrage (§3.3).

2.4 Schéma des métadonnées

Le brief demande explicitement un schéma couvrant **symptômes, antécédents, constantes, source, niveau de confiance** (`METADATA_SCHEMA.md`). Je le documente pour les deux niveaux : les enregistrements de données d'entraînement et le **dossier d'exécution** écrit par l'agent (même forme que l'enregistrement SIH).

Champ (brief)	Clé	Provenance dans le POC
Symptômes	<code>symptoms</code>	Runtime : <code>motif</code> + suivi ; dataset : le texte de la vignette
Antécédents	<code>medical_history</code>	Runtime : texte libre optionnel ; absent du corpus d'examen (limite documentée)
Constantes	<code>vitals</code>	Runtime : saisie optionnelle dans le questionnaire (T°, TA, pouls, SpO₂), injectée dans le prompt et persistée (anonymisée) ; absente du corpus d'examen (dataset). Intégration dispositif en roadmap (§8)
Source	<code>source</code>	dataset : <code>medical_mcqu / _oeq / medquad / llm_triage / vignette</code> ; runtime : <code>chsa-triage-poc</code>
Niveau de confiance	<code>confidence_level</code>	dataset : consensus 3-LLM (unanime 3/3 → <code>high</code> , majorité 2/3 → <code>medium</code>). Runtime : score dérivé (accord règle↔modèle + succès du <i>parsing</i> → <code>high / medium / low</code> ; <code>low</code> → revue clinicien). Version calibrée (<i>logprobs</i>) en roadmap (§8)

2.5 Anonymisation RGPD : la passe corpus + la frontière runtime

Problème. Le brief exige une conformité RGPD **prouvée** (Presidio recommandé), y compris un contrôle qu'« aucune donnée personnelle identifiable ne subsiste ». Mais mes sources sont des questions d'examen et des vignettes synthétiques : le risque théorique de PII est faible — reste à le **démontrer**.

Décision (deux niveaux). - **Passe corpus (offline).** J'ai fait tourner Microsoft **Presidio** + **spaCy** sur **6 695 textes** du corpus, avec un journal d'audit par enregistrement (SHA-256 + entités, **sans stocker le texte brut**). - **Anonymisation au runtime dans l'agent.** Le nœud `anonymisation` est la **frontière RGPD** : tout input patient est anonymisé *avant* tout stockage ; à partir de ce nœud le `raw_text` est effacé, et l'input brut ne survit que sous forme de hash `input_sha256` — « **hash pour la traçabilité, anonymisation pour le stockage** ».

Critère. (1) Garantir l'invariant « aucun identifiant direct dans le dossier persisté », indépendamment de la qualité du modèle NER ; (2) interpréter les résultats de la passe **sans surinterpréter**.

Preuve — les détections brutes (audit `anonymization_audit.json`) :

Entité	Détections
LOCATION	13 298
AGE	3 624
PERSON	3 330
PHONE_NUMBER	470
DATE_TIME	97

Interprétation (le point à clarifier). Ces détections sont **massivement des faux positifs cliniques**, pas de vrais patients : les LOCATION sont surtout des **localisations anatomiques**, les PERSON des **éponymes cliniques** (maladies/signes nommés) et des **personas d'examen génériques** (« Monsieur X », « Madame Y »), les AGE des âges d'énoncé. C'est cohérent avec la nature des sources (questions ECN/pharmacie + vignettes synthétiques) : **il n'y a pas de vrai patient**, donc les données sont non personnelles par construction → hors champ RGPD (**Recital 26**). La passe Presidio ne « nettoie » donc pas des fuites : elle **confirme** l'hypothèse d'absence de PII réelle et documente le processus.

L'architecture de l'anonymiseur (`src/oc14_triage/anonymization.py`) est **à deux couches**, ce qui rend l'invariant robuste. **(a) Presidio+spaCy** pour les entités sémantiques (PERSON, LOCATION) — deux rôles distincts : **spaCy** fournit le modèle de **reconnaissance d'entités nommées (NER)** qui *repère* dans la phrase ce qu'aucune regex ne peut cadrer (un nom, un lieu n'ont pas de forme fixe) ; **Presidio** (Microsoft) est le **cadre d'orchestration** qui combine la sortie de spaCy avec ses propres reconnaisseurs à motifs, attribue un **score de confiance** à chaque détection et pilote le remplacement. **(b) un filet regex inconditionnel** pour les identifiants structurés (téléphone, e-mail, NIR français, IDs numériques longs). Ce filet existe parce que le reconnaiseur de téléphone spaCy FR est peu fiable (score ~0,4) — la regex **garantit** le masquage quel que soit le modèle. Une *allowlist* de noms communs français (motif, douleur, urgence...) évite de corrompre l'entrée par de faux PERSON/LOCATION.

3. Entraînement (méthodologie décision-driven) [↔ TOC](#)

3.1 Modèle de départ : Base (primaire) + Instruct (comparaison)

Problème. Le brief nomme Qwen3-1.7B-Base. Or un modèle *Instruct* possède déjà un comportement de sécurité/refus, précieux pour un POC clinique.

Décision. Affiner **les deux** sur les mêmes données ; **Base est le modèle primaire** (celui que je DPO, fusionne et sers), **Instruct est le bras de comparaison**.

Critère. Honorer le brief tout en montrant le compromis Base-vs-Instruct.

Preuve. J'ai affiné **les deux**, mais **seul Base a été porté jusqu'au bout** (DPO, fusion, serving) ; l'Instruct fut une **sonde exploratoire de départ**, pas un bras des phases finales (il n'apparaît pas dans le tableau de bord final à 5 bras, §7). Le chiffre de référence n'est donc **pas** un Base-vs-Instruct, mais le **gain d'entraînement**, mesuré sur le **même** jeu *gold held-out* de **n=300** (stratifié, sans fuite — cf. §4) : **Base non entraîné macro-F1 0,19 → SFT v9 0,82** — même métrique, même jeu, seul le modèle change. Le 0,19 est le **vrai plancher** d'un Base *non affiné* (il ne sait pas suivre le format de triage), pas une version volontairement faible. (*Une comparaison exploratoire initiale sur n=6, entachée de confusion de gabarit, subsiste dans le journal ; elle est dépassée.*)

3.2 SFT + LoRA via Unsloth

- **SFT** (Supervised Fine-Tuning) : montrer au modèle de bons exemples (instruction → réponse) pour qu'il apprenne notre format de triage et sa persona. **LoRA** (Low-Rank Adaptation) n'entraîne qu'un petit greffon (~0,3 % des poids) — ce qui tient sur un **T4 Kaggle gratuit** de 16 GB.
- **Config.** $r=16$, $\alpha=16$, 4-bit, 2 époques, **seed 3407**, gabarit **ChatML**, `train_on_responses_only` (on n'entraîne que sur la réponse, pas sur le prompt). **Unsloth** (kernels GPU custom, ~2× plus rapide) au-dessus de TRL/PEFT (fallback documenté).
- **Détail d'inférence appris à la dure (Problème #14/#15).** Qwen3-1.7B-Base **ne fournit aucun chat template** → j'ai posé un ChatML explicite. Et le modèle doit **s'arrêter sur** `<|im_end|>` (son `eos` est `<|endoftext|>`) et utiliser le **prompt système complet**, sinon il dégénère (répétitions). C'est aussi exactement ainsi que je le sers.
- **Résultat.** `train_loss` ~0,869 sur le jeu labellisé par consensus, ~79 min sur T4 (≈ **0 €** ; ~1,3 des ~30 GPU-heures/semaine gratuites).

3.3 Gestion du déséquilibre de classes

Problème. Le corpus d'examen sur-représente le grave (~47 % *maximale*). Un premier SFT « propre » (après audit) obtenait macro-F1 0,65 avec un **effondrement de différée** (rappel 0,28) : 72 cas sur 100 poussés à

modérée. Cause : l'exclusion (correcte) des cas non-consensuels avait **affamé** la classe *différée* (les cas ambigus sont souvent des cas bas).

Décision. (a) Relâcher le filtre de consensus à `n_agree ≥ 2` (garder les majorités 2/3 légitimes, ne retirer que les 347 vrais désaccords) ; (b) sur-échantillonner ×8 les 11 vignettes rédigées à la main (porteuses de *différée* équilibrée et de triage EN).

Critère. Restaurer le signal *différée* sans réintroduire de fuite, mesuré sur le même *gold greedy*.

Preuve. *différée* rappel **0,28 → 0,71**, macro-F1 **0,65 → 0,82** (v9). C'est le modèle servi.

3.4 DPO : un négatif instructif, diagnostiqué... puis corrigé

- **DPO** (Direct Preference Optimization) : montrer au modèle des paires (meilleure, moins bonne) réponses pour qu'il préfère la meilleure — alignement sans modèle de récompense séparé.
- **Invariant d'ordonnancement.** Le DPO tourne sur le modèle SFT **adapter LoRA encore attaché** ; la fusion en poids 16-bit se fait **une seule fois, après DPO** — jamais entre les étapes.

Tentative n°1 — l'effondrement. Premières paires de triage « équilibrées par direction » (211/24 : sous-triage 103 + safety 10 / sur-triage 48 / modérée 50), chosen = le bon niveau, rejected = un niveau **adjacent** erroné. Résultat : macro-F1 **0,822 → 0,799**, extrêmes aiguisés (*différée* 0,71 → 0,96) mais **milieu effondré** (*modérée* 0,85 → **0,55**).

Diagnostic (le mécanisme, littérature à l'appui). *modérée* est le niveau **rejected** pour les deux types de paires (sous-triage depuis *maximale*, sur-triage depuis *différée*) : ~168× « la mauvaise réponse » contre 56× « la bonne » → le DPO apprend à **éviter le milieu**. C'est un **déplacement de vraisemblance** (*likelihood displacement*, Razin et al. [2410.08847]) : la perte DPO ne récompense que **l'écart** $\log P(\text{chosen}) - \log P(\text{rejected})$; l'optimiseur peut l'agrandir en **écrasant P(rejected) au point de faire aussi baisser P(chosen)** — la marge grandit, mais la probabilité *absolue* de la bonne réponse chute.

Correction — de meilleures paires + une régularisation anti-effondrement : 1. Distribution rejetée équilibrée — chaque niveau apparaît *choisi* ET *rejeté* en proportions saines, pour ne jamais pénaliser structurellement le milieu (invariant vérifié en test : *modérée* = 53× choisie / 151× rejetée, plus jamais absente du côté « choisi »). **2. Hard negatives** — des paires tirées des **vraies erreurs du SFT** (les cas qu'il rate), pas des inversions de niveau synthétiques. **3. Régularisation anti-effondrement** — `rpo_alpha` de TRL (`DPOTrainer(rpo_alpha=1.0)`) : ajoute à la perte DPO un terme **NLL/SFT sur la réponse choisie** (« continuer le SFT sur la bonne réponse pendant le DPO »), qui **ancre P(chosen) vers le haut** et bloque l'effondrement. Équivalent : **DPO-Positive / Smaug** [2402.13228] (pénalité dès que $P(\text{chosen})$ passe sous celle du modèle de référence).

Preuve — comparaison pommes-à-pommes (mêmes 300 *gold*, même harness, mêmes poids de base, adapter DPO activé/désactivé — seule variable : le DPO) :

n=300, greedy, même harness	macro-F1	rappel maximale	rappel modérée	rappel différée
SFT v9	0,827	0,84	0,88	0,75
SFT v9 + DPO (<code>rpo_alpha</code>)	0,845	0,88	0,83	0,82

(SFT v9 mesuré à 0,827 sur ce harness dédié — cohérent avec le 0,822 canonique de §5.2 à la marge de bruit ; les deux modèles sont notés avec le même harness pour une comparaison valide.)

Plus d'effondrement (les 3 classes 0,82-0,88, vs *modérée* 0,55 en tentative n°1) et un **gain net +0,018**, porté par un meilleur rappel *maximale* (sécurité) et *différée* pour un coût modeste sur *modérée* : un **profil orienté sécurité**, souhaitable en triage. Adapter persisté (HF `ghislaindelabie/oc14-qwen3-1.7b-triage-dpo-rpo`), reproductible (seed 3407), journalisé sur W&B.

Décision. Le **SFT v9 reste servi en V1** : le gain +0,018 est **réel mais modeste** (dans la marge de bruit à n=300) → pas de swap de production sur cette seule base. Mais la leçon **est** le résultat : l'échec initial venait des **paires + l'absence de régularisation, pas de la méthode DPO**. Avec des paires équilibrées et `rpo_alpha`, le DPO **améliore** le modèle sans effondrer le milieu — le levier d'alignement clinique attendu par le brief, désormais **démontré fonctionnel** (et directement extensible : plus de hard negatives, plus de pas).

4. L'agent de triage (architecture) ← TOC

La chaîne LangGraph (StateGraph) — nœuds réels + branche de sécurité. L'état `TriageCase` circule de nœud en nœud ; le nœud `anonymisation` efface le texte brut (frontière RGPD) ; `explication` porte l'unique conditionnelle (override red-flag).



L'agent **est** la chaîne du parcours patient exigée par le brief. Il est implémenté comme un `StateGraph` `LangGraph` (linéaire + un unique override de sécurité conditionnel : la profondeur du framework n'est pas l'exigence graduée — la chaîne l'est).

4.1 Le schéma de la chaîne (= le parcours patient)

```

Patient → UI Gradio → HTTP → API FastAPI (/session/*)
└─ Agent LangGraph :
    collecte (questionnaire adaptatif)
    → anonymisation (Presidio) ← frontière RGPD : raw effacé, seul input_s
    → prétraitement / validation (signes d'alerte)
    → triage (LLM fine-tuné) ← stub | RunPod vLLM (SFT v9)
    → explication (niveau + justification + reco + disclaimer ; override séc
    → persistance (SQLite « dossier », req-id, latence)
    → intégration SIH (enregistrement FHIR-shaped)
  
```

4.2 Chaque composant du cahier des charges

- **Collecte — questionnaire adaptatif** (`questionnaire.py`). Trois champs cœur demandés dans l'ordre (motif → début → intensité 1-10). L'adaptativité : si le motif porte un signal d'alerte connu (ex. « douleur thoracique »), le questionnaire **insère une question de suivi ciblée** (« la douleur irradie-t-elle ? sueurs ? essoufflement ? ») avant de finir. Déterministe et testable — le raisonnement est laissé au LLM en aval. Une réponse vide ne remplit **pas** le champ (on re-pose la question) pour éviter un verdict confiant sur zéro information.
- **Anonymisation** (`anonymization.py` , nœud `anonymisation`). Frontière RGPD (voir §2.5) : masque les identifiants directs, remplace âge/date par `[AGE]` / `[DATE]` (gardés car pertinents au triage), efface le brut, calcule `input_sha256`.
- **Prétraitement / validation**. Détecte les **signes d'alerte** (`detect_red_flags`) et valide l'entrée (non vide).
- **Triage — le LLM fine-tuné** (`backend.py`). Backend **agnostique** : `stub` (réponse structurée canonique, sans GPU — CI/démo/fallback) ou `real` (endpoint vLLM OpenAI-compatible, mêmes réglages que le serving : temperature 0, stop `<|im_end|>`, thinking désactivé). Toute erreur backend → *fallback* structuré sûr (jamais de propagation d'exception).
- **Explication** (nœud `explication`). Parse la sortie en {niveau, justification, recommandation, disclaimer}. **Override de sécurité (l'unique conditionnel de la chaîne) : tout signe d'alerte détecté force l'urgence à maximale.** Une sortie non structurée retombe sur *modérée* par défaut (sûr) plutôt que de planter.
- **Persistance** (`store.py` , SQLite). Écrit le **dossier** post-anonymisation : `session_id` , `interaction_id` , `timestamp` , `model_version` , `symptoms_anon` , `urgence` , `justification` , `recommandation` , `input_sha256` , `disclaimer_present` , `latency_ms` , drapeau `deleted` (droit à l'effacement). **Aucun texte brut, aucune PII.**
- **Intégration SIH** (`sih.py`). Projette le cas dans un **Bundle FHIR R4** (Encounter + Observation) — **simulé** : c'est la *forme* d'un push SIH réel, pas une connexion hospitalière. Le `subject` est **pseudonyme** (le `session_id` synthétique, jamais un nom).

4.3 API, UI, traçabilité

- **API FastAPI** (`service.py`) : `/session/start` , `/session/answer` (pilote le questionnaire tour par tour puis lance la chaîne), `/session/{id}` (historique), `/sessions` , `/health` . Les réponses de session sont en mémoire (transitoires) ; tout ce qui est **persisté** passe d'abord par l'anonymisation.
- **UI patient Gradio** (`agent/ui.py`), avec un accordéon **Traçabilité** montrant en direct le `req-id` , le texte anonymisé stocké et l'absence de nom/téléphone — exactement la correction demandée à l'évaluation précédente.
- **Traçabilité pour audit** : chaque interaction est traçable par `req-id` + `input_sha256` **sans** conserver de donnée personnelle, avec la latence par nœud mesurée dans la trace.

5. Évaluation & métriques ↩ TOC

5.1 Protocole

- **Jeu de test.** *Gold stratifié 100/100/100* (maximale/modérée/différée), **disjoint** du train (pas de fuite), issu du consensus 3-LLM unanime.
- **Décodage greedy** (temperature 0) → **déterministe et reproductible** (une version antérieure utilisait un décodage échantillonné, source d'inflation).
- **Métriques triage-first** (`eval/metrics.py`) : **macro-F1** en tête (l'accuracy brute est *gameable* en sur-prédisant *maximale* ; sur un test équilibré, macro-F1 ≈ accuracy), rappel/précision **par classe**, **intervalles de confiance de Wilson**, **matrice de confusion**, et contrôles comportementaux (présence du disclaimer, respect du format, absence de `<think>`).

5.2 Résultats (SFT v9 servi vs Base)

Métrique (n=300, greedy, sans fuite)	Base (non entraîné)	SFT v9 (servi)
macro-F1	0,19	0,82
accuracy	0,25	0,82
rappel <i>urgence maximale</i> (sécurité)	0,70	0,90 [IC 0,83-0,95]
rappel <i>urgence modérée</i>	0,05	0,85
rappel <i>urgence différée</i>	0,00	0,71
Cohen κ vs gold	—	0,73
format / disclaimer	0,68 / 0,00	1,00 / 1,00

Matrice de confusion (v9, gold → prédit) : maximale 90 ✓ / 9→modérée / **1→différée** ; modérée 85 ✓ / 12→maximale / 3→différée ; différée 71 ✓ / **29→modérée** / 0→maximale.

Lecture. Le fine-tuning achète **0,19 → 0,82** de macro-F1 et enseigne le format + le disclaimer **à partir de zéro** (0,68/0,00 → 1,00/1,00). Le Base, lui, répond « maximale » ou **échoue à produire un niveau exploitable dans ~32 %** des cas (96 réponses `(none)`), ne distingue jamais les niveaux bas, n'émet jamais l'avertissement. Le modèle affiné **ne sous-trie presque jamais** (1 seule urgence rétrogradée à *différée*) mais **sur-trie le bas** (*différée* : 29/100 poussés à *modérée*) — c'est le sens **sûr** du biais, payé en précision.

5.3 L'audit adverse (la rigueur comme atout)

Un score antérieur de **0,81 a été retiré** après un audit adverse du pipeline : il était **gonflé** par (a) une **fuite éval→train** (66 lignes de QA labellisées gold présentes aussi à l'entraînement, retirées), (b) un **décodage échantillonné** qui tombait parfois par chance sur la bonne classe rare, et (c) des lignes non-consensuelles bruitées. Une fois corrigé (greedy + sans fuite), un intermédiaire a mesuré 0,65, révélant l'effondrement de *différée* ; le correctif de rééquilibrage (§3.3) l'a remonté à **0,82** — reproductible et sans fuite, contrairement au 0,81 retiré. Je préfère un 0,82 défendable à un 0,81 flatteur.

5.4 Latence & pertinence

- **Latence.** La chaîne mesure la latence par nœud (trace `ms`) et la latence totale (`latency_ms` dans le dossier). En mode *stub* (CPU, sans modèle) la chaîne complète tourne en quelques millisecondes. La latence **de bout en bout avec le vrai modèle** a été mesurée sur l'endpoint **RunPod** : **~2 s à chaud**. Le cold-start serverless (scale-to-zero) est adressé par une requête de préchauffe (voir §6).
- **Pertinence.** Mesurée par le macro-F1 et le rappel par classe ci-dessus ; complétée par les contrôles comportementaux (format/disclaimer à 1,00) et l'override de sécurité sur les signes d'alerte.

5.5 Parcours de validation — étape par étape

Voici comment j'ai atteint le 0,82 servi. À **chaque** étape j'ai suivi le même rythme : **je mesure → je constate un problème → je diagnostique la cause → je corrige → je re-mesure**. Ce n'est pas une ligne droite : c'est une suite de mesures qui m'ont forcé à revenir sur mes pas. C'est, à mon sens, la partie la plus solide de ce travail.

Étape 1 — le plancher. Avant tout entraînement, je mesure le modèle Base nu sur le même *gold* : **macro-F1 0,19**. Il répond « maximale » par défaut ou échoue à produire un niveau exploitable (~32 % de `(none)`), ne distingue jamais les classes basses, n'émet jamais l'avertissement. *Constat* : ce chiffre fixe le plancher et la valeur ajoutée que le fine-tuning devra démontrer.

Étape 2 — un premier SFT (v8) trop beau... que j'ai retiré moi-même. L'éval initiale du premier SFT sur labels de consensus donne **macro-F1 0,813**. Trop propre. Avant de dépenser plus de GPU, je lance un **audit adverse** du pipeline (`docs/KNOWN_ISSUES.md` , 29 candidats → **16 constats confirmés**). Il révèle trois vices qui

gonflaient le chiffre : (a) une **fuite éval→train** — les mêmes cas cliniques MediQAI, présents dans le *gold*, étaient indépendamment reformés en lignes de QA à l'entraînement ; (b) un **décodage échantillonné non déterministe** (`do_sample=True`, `temp=0.3`, sans seed) qui tombait parfois par chance sur la bonne classe rare ; (c) des **lignes d'entraînement bruitées** (cas non-consensuels étiquetés par un tie-break arbitraire). *Décision* : **RETIRER le 0,813**. Point clé — le correctif n'est pas venu d'un évaluateur, mais de mon propre audit : j'ai détecté et retiré mon meilleur chiffre.

Étape 3 — une éval corrigée... qui expose un nouveau problème. Je corrige les trois vices : dé-duplication garantissant `gold n train = 0`, **décodage greedy déterministe** (temperature 0), et métriques robustes (verdict ancré sur la ligne Niveau d'urgence : , IC de Wilson). Re-mesure : **macro-F1 0,653**. Bien plus bas — mais *vrai*. Et cette éval corrigée met au jour un défaut que le chiffre gonflé masquait : un **effondrement de la classe différée** (rappel **0,28** ; 72 cas sur 100 poussés à *modérée*). *Diagnostic* : le nettoyage (correct) des cas non-consensuels avait **affamé** la classe *différée*, car les cas peu urgents sont sur-représentés parmi les désaccords retirés. Le modèle **sur-triait** systématiquement le bas.

Étape 4 — rééquilibrage → v9, le modèle livré. Je cible la cause, pas le symptôme : (a) j'**assouplis la règle de consensus** (`n_agree ≥ 2` — garder les majorités 2/3 légitimes, ne retirer que les vrais désaccords), ce qui restaure le signal *différée* sans réintroduire de fuite ; (b) je **sur-échantillonne ×8 les vignettes cliniques** rédigées à la main (porteuses de *différée* équilibrée + triage EN). Re-mesure sur le *même gold* greedy : **SFT v9 macro-F1 0,822** — rappel *différée* **0,28 → 0,71**, *maximale* **0,90 [IC 0,83-0,95]**, format/disclaimer **1,00**. **C'est le modèle servi.**

Étape 5 — DPO, un négatif instructif assumé. Je tente d'aligner davantage via un DPO sur des paires de préférences de triage. Re-mesure : **macro-F1 0,799 < 0,822**. *Diagnostic (littérature à l'appui)* : la classe du milieu (*modérée*) était systématiquement le côté « rejeté » des paires (sous-triage depuis *maximale*, sur-triage depuis *différée*) et beaucoup de paires étaient quasi-identiques → un **déplacement de vraisemblance** (*likelihood displacement* — Razin et al. [2410.08847], Smaug/DPO-Positive [2402.13228]) qui **effondre le milieu** (*modérée* 0,85 → 0,55). De plus, la cible d'alignement du DPO (format, disclaimer, escalade) était **déjà saturée à 1,00 par le SFT** → aucune marge à gagner. *Décision* : **conserver le SFT v9** en V1 ; documenter le DPO comme un **négatif bien diagnostiqué — repris et corrigé à l'étape 7**.

Étape 6 — v10, l'amélioration du jeu de données. Le vrai levier du post-mortem DPO n'est pas une autre méthode d'alignement, c'est un **meilleur jeu de données**. Pour réduire le biais de sur-triage résiduel, je **rééquilibre le train** (part *maximale* **54 % → 35 %**, *différée* **12 % → 18 %** — je garde tous les cas *différée* et *modérée*, je plafonne l'abondant *maximale*) et je **garantis une justification clinique réelle par cas** (issue d'un annotateur du consensus, plus de canned fallback). **Entraîné puis évalué** sur le *même gold* : **macro-F1 0,822**, parité stricte avec v9 (matrice identique). Le gain *visé* — la **qualité des justifications** — a depuis été **testé (juge LLM aveugle, n=48) = match nul statistique** (cf. §5.6), donc **v9 reste servi** (`scripts/build_sft_v10.py`).

Étape 7 — DPO, repris et corrigé (`rpo_alpha`). Fort du diagnostic de l'étape 5, je **corrige les paires** (distribution rejetée équilibrée — chaque niveau *choisi* ET *rejeté*) et j'ajoute la **régularisation anti-effondrement** `rpo_alpha` (ancre NLL sur la réponse choisie). Comparaison **pommes-à-pommes** (mêmes 300 *gold*, même harness, mêmes poids de base, adapter DPO activé/désactivé) : **v9 0,827 → DPO 0,845 (+0,018)**, **sans effondrement** (les 3 classes 0,82-0,88), profil orienté sécurité. Le DPO est donc **démontré fonctionnel** ; le gain restant **modeste** (marge de bruit à n=300) → **v9 reste servi en V1**, le DPO corrigé est persisté (HF) et directement extensible (cf. §3.4).

Récapitulatif de la progression :

Étape	Modèle / éval	macro-F1	Statut
1	Base (non entraîné)	0,19	plancher
2	SFT v8 (première éval)	0,813	RETIRÉ (fuite + échantillonnage + bruit)
3	SFT v8 (éval corrigée)	0,653	intermédiaire — expose l'effondrement <i>différée</i>
4	SFT v9	0,822	SERVI
5	SFT v9 + DPO (v1)	0,799	négatif instructif — effondrement <i>modérée</i> diagnostiqué
6	SFT v10	0,822	parité ; justifications testées (juge aveugle n=48) = match nul → non retenu
7	SFT v9 + DPO (rpo_alpha)	0,845	corrigé — +0,018 pommes-à-pommes, sans effondrement (v9 servi en V1)

Ces bras sont journalisés côté **W&B** (projet `oc14-triage-eval`) dans un tableau de bord de **comparaison d'expériences** : *base 0,19 · sft-v8 0,813 RETIRÉ · sft-v8-honnête 0,653 · sft-v9 0,822 SERVI · dpo 0,799 · dpo-rpo_alpha 0,845*. Un W&B Sweep **dédié (learning rate / LoRA r / warmup, early-stop Hyperband)** y ajoute les courbes d'entraînement *live***. Provenance dans `config.kernel` de chaque run (voir §5.6).

5.6 Suivi d'expériences (W&B)

Un tableau de bord W&B compare les 5 bras : *base 0,19 · sft-v8 0,813 RETIRÉ · sft-v8-honnête 0,653 · sft-v9 0,822 SERVI · dpo 0,799*. Ce sont des **résumés d'éval finaux journalisés manuellement** (provenance dans `config.kernel` de chaque run), **pas** des courbes d'entraînement *live* — leur capture continue est câblée et constitue un point d'amélioration MLOps (§8).

Note (V1 servie = SFT v9). Une itération **v10** — *jeu de données amélioré* (justifications de consensus réelles intégrées + rééquilibrage) — a été **entraînée puis évaluée** sur le même *gold* n=300 (T4, greedy, sans fuite) : **macro-F1 0,822**, soit une **parité stricte** avec v9 (rappels 0,90 / 0,85 / 0,71, κ 0,73 — matrice de confusion identique). Le gain *visé* de v10 est la **qualité des justifications** (rationales de consensus réelles) — non captée par la F1 par niveau. Elle a depuis été **testée** par un **juge LLM aveugle** (`claude-opus-4-8` , n=48 cas gold stratifiés, biais de position contrôlé) : **match nul statistique** — v10 l'emporte sur **0,44 [IC 95 % 0,31-0,58]** des cas, à égalité sur chaque critère → **aucun avantage de justifications démontré. Ni gain de métrique ni gain de justifications ne justifiant un redéploiement, v9 reste servi** ; v10 = amélioration de *données* non concluante sur ce POC. (*Note d'intégrité : la sortie du kernel de fusion Kaggle est un merge v9 périmé ; le vrai v10 est l'adapter LoRA — à re-fusionner avant tout déploiement.*)

6. Serving, CI/CD & déploiement ↗ TOC

6.1 Architecture de serving

Deux couches, conteneurisées (Docker) : - **Le modèle** tourne sur **vLLM** (serveur d'inférence rapide, API OpenAI-compatible), cible **RunPod serverless** (pay-per-second, scale-to-zero — le GPU le moins cher, cold-start assumé et préchauffé). - **Un wrapper FastAPI** `/triage (serving/app.py)` devant vLLM, qui : (1) **injecte le prompt système de triage** (l'appelant n'envoie que le texte patient) ; (2) **force le non-thinking + stop sur `<|im_end|>`** ; (3) pose une **API-key gate** (header `X-API-Key`) et un **journal d'audit privacy-safe** (métadonnées seulement, jamais le texte patient). Testé unitairement contre un backend vLLM **mocké**.
L'**agent complet** (§4) est lui aussi exposé par FastAPI et conteneurisé ; le backend de triage bascule du *stub* au vLLM réel via des variables d'environnement, sans changer le code.

6.2 CI/CD (GitHub Actions)

`.github/workflows/ci.yml` : - **lint-and-test** (à chaque push / PR) : `uv sync` , **ruff** (lint), **pytest** (suite complète) — **verts**. La CI ne touche pas de GPU (pas d'entraînement dans le pipeline). - **deploy** (job `workflow_dispatch` manuel)

: build + push de l'image agent vers **GHCR**, puis un refresh d'endpoint **RunPod** gardé derrière le secret `RUNPOD_API_KEY` (no-op sans la clé). Déploiement automatisé et reproductible sans exiger le secret pour la CI de tous les jours.

Secrets : clés en `.env` / secrets GitHub, **jamais commités**.

6.3 Check-list go / no-go (avant pilote)

Contrôle	Seuil / attendu	Statut
<code>/health</code> répond	<code>{"status":"ok"}</code>	✓
Chaîne end-to-end	3 cas de démo donnent le bon niveau	✓ (stub)
Anonymisation RGPD	aucun identifiant direct dans le dossier (test de fuite)	✓
Traçabilité	<code>req-id</code> + <code>input_sha256</code> par interaction, pas de texte brut	✓
Rappel <i>urgence maximale</i>	≥ 0,83 (plancher IC)	✓ (0,90 [0,83–0,95])
Taux de disclaimer	= 1,00	✓
Secrets protégés	clés en <code>.env</code> /secrets, jamais commit	✓
Endpoint cloud vLLM	déployé + latence mesurée	✓ (RunPod, ~2 s à chaud)
Latence (à chaud)	mesurée sur l'endpoint réel	✓ (~2 s, RunPod)

7. Limites (assumées) ↔ TOC

- Standard « argent », pas de vérité clinique.** Les étiquettes sont un consensus de 3 LLM ($\kappa \approx 0,67$), pas un jury de cliniciens. L'accord LLM↔clinicien n'est que *modéré* dans la littérature. À valider cliniquement avant tout usage réel.
- Circularité (le caveat clé d'éval).** Le *gold* = l'étiquette 3-LLM **unanime**, et le modèle est entraîné sur les **mêmes** étiquettes 3-LLM → la métrique mesure la **fidélité d'imitation** aux professeurs, pas la justesse clinique. Pire, le gold est le sous-ensemble **facile** (unanime) → chiffre **optimiste** vs la population complète.
- Compromis sur-triage ↔ précision.** Le modèle ne sous-trie presque jamais (sens sûr) mais sur-trie le bas (*différée* 0,71) ; l'échelle 3-niveaux concentre le biais résiduel dans la classe du milieu. À la limite, un trieur qui appelle tout « modéré-ou-pire » n'a plus de valeur de tri.
- Langue : FR-primaire, bilingue faiblement tenu.** Train 79 % FR / 21 % EN, mais l'EN est presque tout du QA général ; le triage EN à l'entraînement est mince (**32 lignes SFT-train**), et **l'évaluation est 100 % française**. La tâche de triage et son éval sont donc de fait FR-only.
- Représentativité du corpus.** Vignettes d'**examen** → sur-représentation du grave (~47 % maximale vs ~25-30 % en vraies urgences). Un système de production exigerait un jeu de triage ED **réel, collecté prospectivement**.
- Constantes vitales non collectées** (pas d'intégration dispositif) — champ réservé, item de roadmap.
- Intégration SIH simulée** (mock FHIR R4, pas de connexion hospitalière réelle).
- Puissance statistique.** $n=100$ /classe → IC larges (maximale 0,90 → [0,83, 0,95]) ; le plancher de sécurité est la **borne basse 0,83**.
- Barre de sécurité.** ≥ 1 urgence sur 10 manquée au pire cas → **inacceptable pour un triage autonome**. Positionnement : **aide à la décision / human-in-the-loop**.
- Améliorations MLOps différées (assumées) :** capture *systématique* des **courbes d'entraînement W&B live** (un premier W&B Sweep live est en place, cf. §5.5) et une campagne de **latence p50/p95** à plus grande échelle.
- Robustesse hors-distribution.** Sur une entrée **absurde / non-clinique** (charabia), le modèle n'a pas de voie « information insuffisante » : il **confabule** un verdict (observé : charabia → *maximale* avec des signes d'alerte hallucinés). C'est un défaut de **robustesse OOD**, pas d'entraînement sur les vrais cas. Mitigation :

un **garde-fou d'entrée déterministe** (rejeter le charabia *avant* le triage — symétrique de l'override red-flag : « garbage in → on refuse », pas « → maximale »), une voie d'**abstention**, et le **HITL**.

8. Roadmap de passage à l'échelle au CHSA ← TOC

Suivant la phase 3 du brief (« projection industrielle »), voici les jalons pour passer du POC à un pilote, puis à la production.

La cible : un agent toujours *human-in-the-loop*, mais bien plus précis. Le plafond du POC (rappel *maximale* 0,90, précision ~0,88) tient à trois limites franchissables — des **étiquettes « argent »** (consensus LLM, pas de vérité clinique), un **corpus d'examen** non représentatif du flux réel des urgences, et une **petite taille** d'évaluation (n=300). En production, trois leviers combinés visent **≥ 98 % sur la classe critique**, *tout en restant une aide à la décision, jamais un triage autonome* :

- **Données de l'hôpital.** Remplacer le standard argent par des cas de triage **réels, prospectifs et représentatifs du CHSA**, étiquetés et **validés par des cliniciens** (vérité terrain, non plus une pré-annotation LLM) — de loin le levier le plus fort sur la précision.
- **Amélioration continue (LLMOps).** Une boucle de **ré-entraînement** : chaque correction clinique (via le HITL) devient une donnée étiquetée ; monitoring de la dérive → ré-entraînement périodique ; versionnage des modèles/jeux + déploiement canari (le pipeline CI/CD est déjà en place).
- **Le human-in-the-loop lui-même.** L'agent **assiste**, le soignant **décide** et valide/corrige chaque alerte *maximale* : la précision *effective du système* est portée par le clinicien, et ses corrections **ré-entraînent** le modèle — un cercle vertueux qui rapproche progressivement l'agent seul de ce plafond.

Concrètement, les jalons :

1. **Modèle plus grand (32B+).** Passer de Qwen3-1.7B à un modèle 32B+ (le brief le prévoit) pour un gain de raisonnement clinique, avec un budget GPU serving revu (quantisation, batching vLLM).
2. **Données réelles + validation clinique.** Remplacer le standard argent par un jeu de triage ED **réel, collecté prospectivement et représentatif**, sous un **DPA** (accord de traitement des données) ; renforcer l'anonymisation (revue humaine d'un échantillon) ; faire **valider les étiquettes par des cliniciens** (le consensus LLM devient une pré-annotation, plus la vérité).
3. **Intégration SIH réelle.** Passer du mock FHIR R4 à une connexion **FHIR/HL7** authentifiée au SIH du CHSA (Encounter/Observation réels, identités gérées côté SIH, jamais dans le modèle).
4. **Intégration dispositif des constantes.** La **saisie libre** des constantes est déjà en place (questionnaire → prompt → constantes, POC) ; l'étape suivante est l'**intégration dispositif** (capture structurée T°/FC/TA/SpO₂ depuis les moniteurs) et des **seuils d'alerte vitaux** (ex. SpO₂ < 90 % → red-flag), au-delà du raisonnement libre actuel du modèle sur les constantes.
5. **Human-in-the-loop + monitoring/dérive.** Garder la décision finale humaine ; câbler en production les alertes sur taux d'erreur / latence p95, la **dérive du taux d'urgence maximale** (sur-triage), et une revue périodique d'un échantillon par un clinicien. Ajouter un **score de confiance au runtime**, dérivé des **logprobs** de vLLM — la probabilité que le modèle attribue au *token* du niveau d'urgence qu'il a choisi (proba élevée → sûr ; hésitation entre deux niveaux → proba basse) — afin de **router automatiquement les cas peu sûrs vers une revue clinique**. C'est un signal bien plus fiable qu'une confiance auto-déclarée par le modèle (« je suis sûr à 80 % », notoirement mal calibrée).
6. **DPO d'alignement clinique.** Refaire un DPO ciblé (paires rééquilibrées pour ne pas écraser *modérée*) pour forcer le sous-triage résiduel vers zéro — c'est le rôle « conformité protocoles » attendu du DPO.
7. **MLOps.** Tracking W&B live (courbes d'entraînement, pas seulement les résumés), pipeline de **ré-entraînement** déclenché sur dérive ou nouvelle donnée validée, versionnage des modèles et des jeux, déploiement canari via le job CI/CD déjà en place.
8. **Recherche d'hyperparamètres.** Le brief invite à « itérer sur les hyperparamètres ». Pour le POC j'ai retenu des valeurs par défaut éprouvées (recommandations Unsloth pour Qwen3-1.7B) et concentré l'effort sur la **qualité des données** — le correctif *différée* a rapporté **+0,17 de macro-F1**, bien plus qu'un réglage fin ne l'aurait fait. Prochain levier : un **sweep systématique** (W&B Sweeps, grille ou bayésien) optimisant le macro-F1 et surtout le **rappel maximale** sur le gold — côté SFT sur le **rang LoRA r et alpha**, le **learning rate**, le **nombre d'époques**, le **dropout LoRA**, les **modules cibles**, le **warmup** ; côté DPO sur le **beta** (**force de régularisation**) et le **learning rate**. À brancher sur le tracking W&B et la boucle de ré-entraînement (point 7).
9. **Bilinguisme complet** (si requis) : grossir le triage EN à l'entraînement + ajouter une tranche d'éval EN indépendante (ex. medical-triage-500).
10. **Questionnaire adaptatif hybride (piste majeure — un projet à part entière).** Aujourd'hui la collecte est **déterministe** (table de règles + un suivi ciblé sur *red-flag*) : sûre et testable, mais figée. L'évolution serait un **workflow hybride** — un squelette déterministe qui **garantit les étapes obligatoires** (motif, antécédents, constantes, dépistage des *red-flags*) et, à l'intérieur de ce cadre, un **LLM entraîné à raffiner les questions** : reformuler, approfondir, et choisir la **prochaine question la plus informative** selon les réponses déjà données — pour une collecte d'information **plus riche** sans jamais sauter une étape critique.

Cela suppose ses propres garde-fous (sécurité conversationnelle, évaluation de la *qualité de collecte*), d'où un chantier distinct du présent POC.

9. Conclusion ↩ TOC

J'ai livré un **POC d'agent de triage médical** couvrant les cinq livrables du brief : un dataset bilingue anonymisé et documenté (RGPD, Recital 26), un modèle Qwen3-1.7B spécialisé par SFT+LoRA (avec une tentative de DPO analysée), un agent complet exposé par API et servi sur un endpoint vLLM/RunPod déployé, un pipeline CI/CD vert, et ce rapport.

Le résultat central est un **signal de progrès net : macro-F1 0,19 → 0,82** entre le modèle Base non entraîné et le SFT servi, avec un rappel de 0,90 sur les urgences vitales et un format/disclaimer parfaits. La démarche a été **rigoureuse et transparente** : audit adverse, fuite éval→train éliminée, intervalles de confiance reportés, un score gonflé (0,81) retiré, et un DPO documenté comme résultat négatif instructif plutôt que survendu.

Surtout, je positionne ce système pour ce qu'il est : une **aide à la décision sous supervision humaine, pas** un trieur autonome. La barre de sécurité n'est pas encore atteinte pour un usage autonome, et les étiquettes restent un standard argent à valider cliniquement. La roadmap (§8) trace la voie du POC vers un pilote crédible : modèle plus grand, données réelles validées par des cliniciens, intégration SIH réelle, collecte des constantes, human-in-the-loop et MLOps. Le POC démontre la **faisabilité technique** et la **valeur clinique potentielle** demandées — avec la rigueur méthodologique qu'exige un déploiement en santé.

↗ Contents

OC14 — Runbook de démonstration (POC agent de triage CHSA)

Comment lancer, démontrer et « aller/ne pas aller » (go/no-go) le POC. Complète le rapport et la soutenance.

1. Architecture (= la chaîne du parcours patient) ↩ TOC

```
Patient → UI Gradio -HTTP▶ API FastAPI (/session/*)
└─ Agent LangGraph :
    collecte (questionnaire adaptatif)
    → anonymisation (Presidio) ← frontière RGPD : raw effacé, seul input_s
    → prétraitement / validation (signes d'alerte)
    → triage (LLM fine-tuné) ← stub | RunPod vLLM (SFT v9)
    → explication (niveau + justification + reco + disclaimer ; override séc
    → persistance (SQLite « dossier », req-id, latence)
    → intégration SIH (enregistrement FHIR-shaped)
```

2. Lancer la démo (mode stub — aucune GPU requise) ↩ TOC

Deux terminaux, depuis la racine du dépôt :

```
# Terminal 1 – API + agent
OC14_TRIAGE_STUB=1 uv run uvicorn oc14_triage.agent.service:app --port 8080

# Terminal 2 – interface patient
AGENT_SERVICE_URL=http://localhost:8080 uv run python -m oc14_triage.agent.ui
# → Gradio sur http://localhost:7860
```

Vérification avant de passer en direct : `curl -s localhost:8080/health → {"status":"ok"}`.

Basculer sur le vrai modèle (RunPod vLLM, SFT v9) : ne pas définir `OC14_TRIAGE_STUB` ; définir `VLLM_BASE_URL` (`https://api.runpod.ai/v2/<endpoint>/openai/v1`), `OC14_MODEL_ID`, `VLLM_API_KEY=$RUNPOD_API_KEY`. Envoyer **une requête de préchauffe** avant la séance (cold start serverless).

3. Cas de démonstration (présenter le `█` en premier) [↩ TOC](#)

#	Saisies (motif → suivi → début → intensité)	Niveau attendu
1 <code>█</code> maximale	douleur thoracique → oui, irradie dans le bras gauche, sueurs → il y a 30 min → 9	urgence maximale (override signe d'alerte + branche de suivi adaptatif)
2 <code>█</code> modérée	mal de ventre depuis hier avec nausées → hier → 6	urgence modérée
3 <code>█</code> différée	petit rhume léger, nez qui coule → 2 jours → 2	urgence différée
4 <code>█</code> RGPD	Je m'appelle Jean Dupont, tél 06 12 34 56 78, forte fièvre → ce matin → 7	montre [NOM] / [TEL] dans le panneau de traçabilité tout en triant

Après le cas 1, ouvrir l'accordéon **Traçabilité** : montrer le `req-id`, le texte **anonymisé** stocké, et l'absence de nom/téléphone dans le dossier (la correction de la remarque d'évaluation précédente, en direct).

4. Check-list go / no-go (avant mise en service pilote) [↩ TOC](#)

Contrôle	Seuil / attendu	Statut
/health répond	<code>{"status":"ok"}</code>	<code>█</code>
Chaîne complète end-to-end	les 3 cas donnent le bon niveau	<code>█</code> (stub)
Anonymisation RGPD	aucun identifiant direct dans le dossier persistté (test de fuite)	<code>█</code> (test <code>test_graph / test_service</code>)
Traçabilité	<code>req-id</code> + <code>input_sha256</code> par interaction ; pas de texte brut	<code>█</code>
Rappel <i>urgence maximale</i>	$\geq 0,83$ (plancher IC, SFT v9)	<code>█</code> (0,90 [0,83-0,95])
Taux de disclaimer	= 1,00	<code>█</code>
Secrets protégés	clés en <code>.env</code> /secrets GitHub, jamais commit	<code>█</code>
Endpoint cloud (vLLM)	requête de préchauffe OK + latence mesurée	<code>█</code> (RunPod, après clé)
Latence	p50/p95 mesurées en conditions réelles	<code>█</code> (mesure sur endpoint réel)

5. Limites d'usage (à communiquer aux utilisateurs) [↩ TOC](#)

- **Aide à la décision, pas triage autonome** : l'agent assiste le personnel soignant ; la décision finale reste humaine (« human-in-the-loop »).
- **Ne pose pas de diagnostic, ne prescrit pas** ; escalade systématiquement les signes d'alerte ; termine toujours par un avertissement.
- **Standard « argent »** : étiquettes issues d'un consensus de 3 LLM ($\kappa \approx 0,67$), non d'un jury clinicien — à valider cliniquement avant tout usage réel.

- **Évaluation 100 % française** ; couverture EN de triage minime à l'entraînement (limite documentée).
- **Constantes vitales non collectées** dans le POC (pas d'intégration dispositifs) — prévu au passage à l'échelle.
- **POC** : intégration SIH simulée (enregistrement FHIR-shaped, pas de connexion hospitalière réelle).

6. Surveillance post-déploiement (prévu) [↔ TOC](#)

- Journal d'audit par interaction (`req-id` , `input_sha256` , niveau, latence) — déjà écrit par le nœud de persistance.
- À câbler en production : alerte sur taux d'erreur / latence p95, dérive du taux d'*urgence maximale* (sur-triage), et revue périodique d'un échantillon par un clinicien.